

PRD-V1.1 制造业 MES 业务分析 Agent 产品需求文档

文档版本: V1.1 编制日期: 2026-09-04 项目名称: 基于 LangGraph+RAG 的制造业 MES 业务分析智能体 文档用途: 面试作品集、项目交付文档; 重点强化 Agent 角色说明书、幻觉治理、人机协同、风险、演进方案等面试加分模块。 运行环境: Python venv; 本地 BGE-small-zh-v1.5 + Chroma 向量库; DeepSeek-Chat LLM API

核心加分模块: Agent 角色说明书、工具风险定义、幻觉治理策略、人机协同设计、生产演进路线。

1 项目定位

1.1 项目背景

制造业数字化售前、方案顾问在输出 MES 相关业务分析时,需要翻阅大量行业 PDF 文档(实施手册、行业白皮书、规范文档),针对紧急插单、OEE 损失、报工风险、物料齐套、合规风险等业务点输出风险分析、改善建议。传统模式痛点:

1. 资料多,人工查阅效率低;
2. 输出质量高度依赖顾问个人经验;
3. 风险分级、对策整理重复性工作多;
4. 缺少标准化输出模板,方案材料格式不统一。

本项目不是简单问答 RAG Demo,而是面向 B 端业务的思考型 Agent,引入规划、工具调用、反思校验闭环,降低售前业务材料撰写成本。

1.2 项目定位

 **定位: B 端业务辅助型智能 Agent, 制造业售前顾问的业务分析助手**

- 产品形态: 命令行版本智能体,后续可扩展 Web 前端;
- 价值: 辅助人产出业务分析报告, **不替代人做最终决策**;
- 技术特点: Embedding、向量检索本地离线运行; 仅文本生成调用远程 LLM API;
- 业务载体: MES/制造业数字化业务风险分析;
- 能力边界: 基于已有 PDF 知识库做分析,输出草稿级业务材料,必须人工复核后使用。

1.3 用户画像

用户角色	描述	核心诉求
售前顾问/方案工程师	制造业售前,需要快速输出风险分析、方案片段	快速拿到结构化分析草稿,减少翻阅资料时间
项目学习者(本集)	(本 AI Agent 方向求职人员,用于作品集)	完整 Agent 工程实践,掌握规划-工具-反思闭环 RAG 架构

1.4 非目标(版本边界,面试必讲)

1.  不替代人类顾问输出最终交付方案,输出内容仅作为草稿;
2.  不做本地大模型推理,文本生成依赖第三方 LLM API;
3.  当前版本无 Web 界面,PDF 需要提前构建向量库,运行时不支持动态上传;
4.  不做账号、权限、多租户管理;
5.  不直接对接真实 MES 系统做数据读写,仅基于静态文档知识库分析。

2 用户场景

场景 1: 业务风险快速分析(核心场景)

场景描述: 售前拿到客户业务痛点,例如“MES 紧急插单会带来哪些风险,有哪些改善措施?”,需要快速整理风险点、分级、对应对策。 **用户行为:** 输入业务问题 → Agent 自动拆解任务、检索本地 PDF 知识库、多轮反思迭代 → 输出 Markdown 结构化报告。 **期望输出:** 包含概述、风险点、连锁影响、高/中/低风险表格、改善建议、总结,可直接复制到方案 PPT/Word。

场景 2：业务知识点调研

场景描述：顾问对某制造业概念不熟悉，需要基于内部文档获取业务解读。用户输入：“OEE 设备综合效率损失主要分为哪几类？”，Agent 检索知识库输出结构化解读。

场景 3：草稿质量迭代优化

场景描述：第一轮输出内容不全，Agent 反思节点识别信息缺失，自动重新检索知识库，迭代优化报告内容，不需要人工重新提问。

3 Agent 角色说明书【核心加分项】

定义 Agent 身份、能力、约束、禁止行为，用于约束 LLM 输出，面试可以讲“给 Agent 做角色契约，约束幻觉”

3.1 Agent 身份

你是一名制造业 MES 业务分析助手，面向售前顾问，基于给定知识库文档片段完成业务分析。你的输出是业务草稿，不能充当客户最终决策依据。

3.2 能力清单

1. 接收制造业业务问题，拆解分析任务，明确需要检索哪些业务维度；
2. 调用 RAG 工具，从本地 PDF 知识库获取参考文档片段；
3. 基于检索到的材料，输出业务分析草稿；
4. 自我反思校验：检查风险点完整性、对策完备性、是否脱离知识库；
5. 识别信息不足时，主动触发重新检索工具获取更多资料；
6. 输出标准化 Markdown 报告，风险点使用表格分级展示。

3.3 硬性约束（契约约束）


1. 所有业务结论必须优先引用检索返回的知识库片段；知识库没有的内容，必须明确标注“知识库无相关描述，该内容为模型推演，需要人工核实”；
2. 禁止编造 MES 流程、行业标准、合规条款；
3. 不输出没有依据的绝对化结论；
4. 输出风险改善建议，区分“业务方案建议”和“强制行业规范”；
5. 不做客户项目的最终决策，报告结尾强制增加提示：**本报告为 AI 辅助草稿，务必业务人员复核确认后使用。**

3.4 禁止行为

1. 禁止编造不存在的行业标准、客户案例；
2. 知识库无信息时，禁止强行编造业务答案；
3. 禁止输出通用大模型的网上常识，优先使用本地知识库内容；
4. 不输出代码、不做系统实施配置，只做业务分析。

4 系统架构与任务流转

4.1 系统架构 Mermaid



flowchart LR

```
subgraph "本地 Venv 运行环境"
    User[用户业务查询]
    subgraph LangGraph_Agent["LangGraph Agent 编排层"]
        N1[planner_node<br/>任务拆解规划]
        N2[tool_decide_node<br/>工具决策]
        N3[tool_exec_node<br/>RAG 检索执行]
        N4[task_execute_node<br/>生成业务草稿]
        N5[reflect_node<br/>反思校验&重规划<br/>幻觉校验]
        N6[summary_node<br/>报告润色汇总]
    end
end

subgraph LocalRAG["本地离线 RAG 模块"]
    Emb[BGE-small-zh-v1.5<br/>本地 CPU Embedding]
    ChromaDB[(Chroma 向量库<br/>./chroma_db 本地磁盘)]
    PDFDoc[本地 PDF 知识库<br/>MES 业务文档]
end

RemoteLLM[DeepSeek-Chat API<br/>远程文本生成服务]

User --> N1
N1 --> N2
N2 --> N3
N3 --> N4
N4 --> N5
N5 --> N6
N6 --> User
```

N2 --> N3
 N3 -. -> Emb
 Emb -. -> ChromaDB
 ChromaDB -. -> N3


 N1 -.调用.-> RemoteLLM
 N4 -.调用.-> RemoteLLM
 N5 -.调用.-> RemoteLLM
 N6 -.调用.-> RemoteLLM

 N3 --> N4
 N4 --> N5
 N5 -.信息不足，闭环迭代.-> N2
 N5 --> N6

 PDFDoc -.构建阶段.-> Emb
 Emb -.构建阶段.-> ChromaDB

 N6 --> OUT[Markdown 业务草稿报告]

4.2 任务流转 Mermaid



flowchart LR

Start[开始 用户输入业务问题] --> Planner[planner_node
任务拆解，生成执行计

划]

Planner --> Decide[tool_decide_node
工具决策：调用 RAG 检索]
Decide --> Retriever[tool_exec_node
检索向量库，返回文档片段]
Retriever --> Draft[task_execute_node
基于知识库生成业务草稿]
Draft --> Reflect[reflect_node
反思校验：完整性+幻觉校验]

Reflect -.知识库信息不足，迭代重跑.-> Decide

Reflect --> Summary[summary_node
输出标准化 Markdown 草稿报告]
Summary --> End[结束，交付人工复核]

```
classDef nodeStyle fill:#e8f4ff,stroke:#2b7bba,stroke-width:2px
classDef startend fill:#cce5ff,stroke:#004085
class Start,End startend
class Planner,Decide,Retriever,Draft,Reflect,Summary nodeStyle
```

4.3 AgentState 状态定义

```
class AgentState(TypedDict):
    user_query: str # 用户原始业务查询
    plan: str # planner 任务拆解执行计划
    context_docs: Annotated[list, operator.add] # RAG 检索返回文档片段
    task_result: str # 业务分析草稿
    reflect_note: str # 反思校验输出：问题点、是否需要重新检索
    need_research: bool # 是否触发二次检索迭代标志
    final_report: str # 最终输出草稿报告
```

5 工具风险、幻觉治理【面试重点加分模块】

5.1 工具风险清单

风险类型	风险描述	缓解方案
检索偏差风险	向量检索返回语义相似，但业务无关的文档片段，带来错误上下文	1.设置 top-4 检索；2.反思节点校验草稿与检索片段的匹配度；3.知识库文档做预处理，过滤无效文档
知识库覆盖不足	用户提问内容不在 PDF 知识库中，无参考材料	Agent 契约约束：知识库无信息时明确标注，禁止编造答案
API 调用异常	网络超时、限流、密钥失效，流程中断	Agent V1.1 迭代增加异常捕获，异常友好提示，记录断点状态
文档质量风险	原始 PDF 文档本身存在错误，Agent 继承错误信息	输出强制提示：原始文档的错误会传导至输出，需要人工复核源文档
迭代爆炸风险	反思节点无限循环反复检索	增加最大迭代次数阈值，例如最多迭代 3 次，到达上限直接输出现有材料并标注限制

5.2 幻觉治理策略（多层防护，面试可以分层讲）

四层防护体系：角色契约约束 → RAG 上下文约束 → 反思校验节点校验 → 输出强制提示
1. 第一层：Agent 角色契约约束（Prompt 层） 在每一次 LLM 调用 System Prompt 植

入角色说明书，强制要求：业务结论必须来自检索上下文；知识库没有内容不强行作答，需要显性标注。

- 2. **第二层：RAG 检索上下文隔离** LLM 生成草稿时，仅把检索返回的文档片段作为参考上下文，禁止模型调用模型内置的通用知识直接作答业务结论。
- 3. **第三层：reflect_node 反思校验节点（核心技术手段）** 反思节点专门做幻觉校验，校验 3 个维度：
 - ①内容完整性：风险点、改善对策是否完整；
 - ②事实对齐：输出的业务结论是否能够在检索到的文档片段找到依据；
 - ③幻觉识别：识别模型自行编造的流程、标准、案例。

如果发现事实无法对齐，标记 need_research=True，触发重新检索；达到最大迭代次数，则输出现有结果并标注局限性。

- 4. **第四层：输出层强制风险提示** 每一份输出报告末尾强制追加固定文本：

⚠️ 提示：本报告为 AI Agent 辅助生成草稿，内容来源于本地知识库文档，存在幻觉与信息不全风险，必须由业务人员复核确认后才可用于正式项目交付。

6 人机协同设计【加分项】

定位：Agent 是助手，不是替代人，明确机器干什么、人干什么。

6.1 人机分工矩阵

工作内容	Agent（机器）承担	人类（售前顾问）承担
业务问题输入	不做，由人输入明确业务问题	人明确业务目标、业务边界，提出问题
知识库检索、资料整理	✅ 自动完成多轮检索、素材汇总	❌ 人不再手动翻阅大量 PDF
输出结构化草稿报告	✅ 输出 Markdown 草稿，风险表格整理	❌ 不输出最终正式交付物
事实校验、业务真伪判断	做初步校验，不能完全保证正确性	✅ 人工做最终事实复核，识别幻觉
客户业务场景适配	不理解客户真实现场情况	✅ 结合客户工厂实际，裁剪、修改 Agent 输出内容
对外正式交付输出	❌ 禁止直接对外交付	✅ 人工修改完善后对外输出方案材料

6.2 人机协同工作流程

- 1. **人发起**：业务人员输入业务问题；
- 2. **机器执行**：Agent 完成任务拆解-检索-生成-反思迭代，输出草稿报告；
- 3. **人复核**：
 - 核对业务结论是否匹配知识库原文；
 - 剔除 AI 幻觉、错误推演内容；
 - 结合客户现场实际业务做修改；
- 4. **人产出最终交付物**：基于 Agent 草稿整理成正式方案文档。

6.3 边界说明

Agent 解决的是资料检索、素材整理、草稿撰写的重复劳动；业务判断力、客户现场理解、最终决策完全交给人。

7 功能需求

7.1 功能需求 FR

FR-001 向量库构建能力

- 读取本地 PDF 制造业文档；文本递归切分 chunk_size=800, overlap=120；

- BGE-small-zh-v1.5 本地 CPU 向量化；向量持久化存储至./chroma_db；控制台输出构建日志。

FR-002 LangGraph 多节点 Agent 工作流

1. planner_node: LLM 完成任务拆解，输出业务分析执行计划；
2. tool_decide_node: 工具决策，判断调用 RAG 检索；
3. tool_exec_node: 向量检索 top4 文档片段，存入 AgentState；
4. task_execute_node: 基于计划+检索上下文输出业务草稿；
5. reflect_node 反思校验节点：完整性校验 + 幻觉事实校验；输出是否需要再次检索标记；设置最大迭代次数（最多 3 次迭代，防止死循环）；
6. summary_node: 输出标准化 Markdown 报告；
7. 每个节点输出控制台日志，便于调试；输出 Mermaid 拓扑图。

FR-003 报告输出规范 报告固定结构：概述、业务风险、连锁影响、风险分级表格（高/中/低风险+缓解措施）、总结； 报告末尾固定追加幻觉风险提示文本。

7.2 非功能需求

类别	需求
性能	RAG 检索毫秒级；完整流程 10-30s，取决于 API 响应；Embedding 本地 CPU 运行
可观测	节点日志输出；Mermaid 流程图；迭代次数可查看
安全	PDF、向量库全部本地存储；仅 prompt 发送给 LLM API；密钥存.env，禁止硬编码
鲁棒性	设置最大迭代次数，避免无限循环检索
可扩展性	节点可扩展；支持后续接入联网搜索、WebUI、报告导出

8 生产演进方案（版本迭代路线，面试讲工程落地思维）

从当前 V1.0 原型版本，向可用于内部业务生产的版本分阶段演进。

V1.0 当前原型版本（作品集版本）

- 形态：命令行程序；本地 RAG+LangGraph 反思 Agent；
- 局限：无异常捕获；无 Web 界面；PDF 需要提前预处理构建向量库；
- 使用场景：项目验证、作品集演示。

V1.1 工程加固版本（可用做内部测试）

1. 增加 API 异常捕获、超时处理、错误日志记录；
2. 实现报告自动导出为本地.md 文件；
3. 接入 Tavily 联网搜索工具，实现「本地 PDF 知识库 + 互联网补充资料」混合检索；
4. 完善迭代次数控制，防止无限循环；
5. 增加检索结果溯源，报告中可以标注对应文档片段来源。

V1.2 产品化版本（内部业务试用）

1. 开发 Streamlit Web 前端界面；
2. 支持网页端上传 PDF，自动完成切片、构建向量库；
3. 界面可视化展示完整 Agent 链路：任务计划、检索片段、草稿、反思意见、最终报告；
4. 支持多知识库切换（汽车 MES、装备 MES 等不同行业知识库）；
5. 增加简单使用记录日志。

V2.0 企业内部生产版本

1. 多租户、知识库权限管理;
2. 对接企业内部文档库, 自动同步文档;
3. 支持多 Agent 调度;
4. 知识库质量评估工具, 统计幻觉、检索错误的案例, 持续优化 Prompt 与知识库。

9 风险与约束汇总

1. LLM 幻觉无法 100%消除, 本产品定位是辅助草稿工具, 不能替代业务人员;
2. 输出质量高度依赖原始 PDF 知识库的完整性、正确性;
3. 当前版本依赖 DeepSeek 第三方 API, 存在 API 服务不可用的外部依赖风险;
4. 最大迭代次数限制, 当知识库信息严重不足时, Agent 只能输出有限信息并标注局限性。

10 附录

10.1 部署依赖

```
pip install langgraph langchain-openai langchain-community langchain-huggingface  
langchain-chroma pypdf python-dotenv
```

10.2 关键 Prompt 摘要

1. planner_node: 对用户制造业业务问题拆解, 输出清晰的执行计划, 明确需要检索哪些业务维度;
 2. task_execute_node: 严格基于检索返回的文档片段生成业务草稿;
 3. reflect_node: 双重校验: ①业务要点完整性; ②输出内容是否可以匹配检索上下文, 识别编造内容;
 4. summary_node: 整理输出 Markdown 报告, 风险表格化, 追加风险提示。
-